

# Sistemas de Inteligencia Artificial

## Métodos de Aprendizaje NO Supervisado

25 de abril de 2022

# Aprendizaje No Supervisado

- Aprendizaje Supervisado vs. No Supervisado.
- Modelo de Kohonen: Mapas Auto-organizados.
- Modelo de Hopfield.
- Análisis de Componentes principales.
- Regla de Oja.

# ¿Qué es el Aprendizaje Automático?

- Un programa que aprende con la experiencia a realizar una tarea.
- Un programa que puede generalizar a partir de un conjunto de datos de entrenamiento.
- Un programa que, dado un conjunto de entrenamiento puede calcular parámetros para optimizar una función objetivo.

# Aprendizaje Supervisado vs. No Supervisado

## Aprendizaje Supervisado

Desarrolla modelos en los que los datos tienen **etiquetas previamente conocidas** que utilizamos para **entrenar** el modelo.

# Aprendizaje Supervisado vs. No Supervisado

## Aprendizaje Supervisado

Construyen modelos de predicción basándose en el conocimiento de la variable Respuesta del conjunto de entrenamiento.

## Aprendizaje NO Supervisado

Construyen modelos de predicción cuando la variable Respuesta no es una información disponible.

# Comenzamos con un ejemplo

Deseamos conocer cuáles son los factores relacionados con el **riesgo de enfermedad coronaria**.

Del conocimiento previo sabemos que el riesgo está relacionado con los siguientes factores:

- presión arterial
- edad
- obesidad
- tiempo desde que se ha diagnosticado hipertensión arterial
- el pulso
- stress

# Ejemplo


Para una investigación se seleccionan al azar 20 pacientes hipertensos sobre los que se midieron las siguientes variables:

- $X_1$ : Presión arterial media (mm Hg)
- $X_2$ : Edad (años)
- $X_3$ : Peso (Kg).
- $X_4$ : Superficie corporal ( $m^2$ )
- $X_5$ : Duración de la Hipertensión (años)
- $X_6$ : Pulso (pulsaciones/minuto)
- $X_7$ : Medida del stress.

# Ejemplo Riesgo Cardíaco

**La dimensión inicial del problema planteado es 7.**  
Si consideramos 2 variables.

Figura: Presión vs Edad





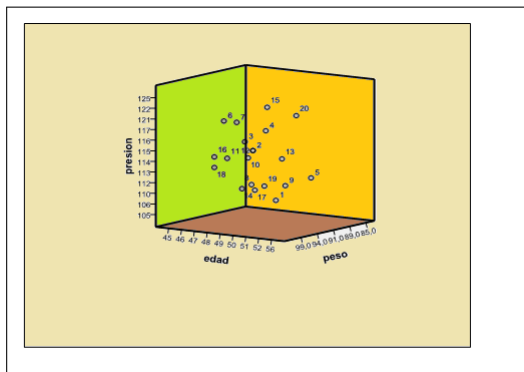
# Ejemplo Riesgo Cardíaco: Presión vs. Edad

## ¿Qué nos dice el gráfico?

- Dos individuos con representaciones próximas en este gráfico tendrán características similares en estas dos variables.
- Dos individuos alejados tendrán características diferentes en las mismas.

# Representación tridimensional de las variables presión vs edad y peso

Figura: Presión vs Peso y Edad



# Nos preguntamos

¿es posible definir un índice que cuantifique la situación de riesgo cardíaco de un paciente con hipertensión arterial...  
**teniendo todas las variables en cuenta?**

# Aprendizaje NO Supervisado

## ¿Qué problemas queremos resolver?

- Agrupamiento
- Asociaciones
- Reducción de la dimensionalidad

# Agrupamiento

## ¿Qué hacen?

- Agrupan observaciones de forma tal que el grado de similitud entre miembros del mismo grupo sea lo más fuerte posible.

Esto implica definir el concepto **similitud**.

# Memorias Asociativas - Definición

Consiste en...

el almacenamiento y recuperación de información por asociación con otras informaciones.

# En esta materia

## Estudiaremos

métodos de aprendizaje no supervisado que se resuelvan con redes neuronales.

# Recordatorio: Variables estandarizadas

Tenemos las variables  $\{X_1, \dots, X_p\}$ , cada una posee  $n$  registros.

- La media de  $X_i$ :  $\bar{X}_i = \frac{1}{n} \sum_{j=1}^n X_i^j$
- La desviación estándar de  $X_i$ :  $s_i = \frac{1}{n} \sum_{j=1}^n (X_i^j - \bar{X}_i)^2$
- Las variables estandarizadas:

$$\tilde{X}_i = \frac{X_i - \bar{X}_i}{s_i}$$



# Ejemplo: Países de Europa

<b>Country</b>	<b>Area</b>	<b>GDP</b>	<b>Inflation</b>
Austria	83871	41600	3.5
Belgium	30528	37800	3.5
Bulgaria	110879	13800	4.2
Croatia	56594	18000	2.3

# Variables del conjunto de datos




Figura: Datos en crudo y estandarizados

# Variables estandarizadas vs. Normalizadas




Figura: Datos en crudo, estandarizados y normalizados

# Referencias

- Metodo de Hopfield [1].
- Método de Kohonen [3, 4].
- Para todos los métodos [2].

- [1] McKay D.J.C. *Hopfield Networks*. Information Theory, Inference and Learning Algorithms, Cambridge, 2003.
- [2] Anders Krogh John Hertz and Richard Palmer. *Introduction to the Theory of Neural Computation*. Addison-Wesley, 1991.
- [3] T. Kohonen. Self-organized formation of topologically correct feature maps. *Biological Cybernetics*, 1(43):59–69, 1982.
- [4] T. Kohonen. The self-organizing map. *Neurocomputing*, pages 1–6, 1998.