

Aprendizaje NO Supervisado: Componentes Principales y Redes Neuronales

11 de mayo de 2022

Componentes Principales - Aprendizaje no supervisado

- Las componentes principales son utilizadas para extraer características destacadas o importantes de un conjunto de datos bajando la dimensión del mismo.
- Por ejemplo la componente Y_1 nos permite agrupar los registros que tengan valores de Y_1 parecidos.
- O también ordenar registros de acuerdo a esta característica.

Componentes Principales - Redes Neuronales

- Algunos modelos de redes neuronales permiten calcular las componentes principales en forma iterativa, ofreciendo ventajas computacionales.

Perceptron Lineal Simple

Dados m datos de entrada, x^1, \dots, x^m , $x^i \in \mathbb{R}^N$, $\forall i$, una red neuronal calcula la salida

$$O^n = \sum_{j=1}^N w_j^n * x_j^i$$

donde $w^n \in \mathbb{R}^N \forall n$.

Actualizar los pesos, ζ la verdadera

$\Delta w_j = \eta(\zeta - y^n)x_j^i$, η es la tasa de aprendizaje.

$$w_j^{n+1} = w_j^n + \eta(\zeta - y^n)x_j^i$$

Regla de Aprendizaje Hebbiano para Aprendizaje No supervisado

Dados m datos de entrada, x^1, \dots, x^m , $x^i \in \mathbb{R}^N$, $\forall i$, una red neuronal calcula la salida

$$y^n = \sum_{j=1}^N w_j^n * x_j^i$$


donde $w^n \in \mathbb{R}^N \forall n$.

Actualizar los pesos

$\Delta w_j = \eta y^n x_j^i$, η es la tasa de aprendizaje.

$$w_j^{n+1} = w_j^n + \eta y^n x_j^i$$

Arquitectura para Aprendizaje Hebbiano simple



La unidad de salida es lineal $y^n = \sum_{j=1}^N w_j^n * x_j^i$.

¿A qué converge?

Oja demostró que

Si la red anterior converge, el vector de pesos resultante w^{final} sería un punto sobre la dirección de máxima variación de los datos, o sea... la primer componente principal.

pero...

el problema es que no converge porque el $\|w^n\|$ va aumentando en cada paso y se hace tan grande que produce que el algoritmo sea inestable.

La propuesta de Oja (1982)


Dr. Erkki Oja, Helsinki University of Technology, Finland

$$w_j^{n+1} = \frac{w_j^n + \eta y^n x_j^n}{(\sum_{j=1}^N (w_j^n + \eta y^n x_j^n)^2)^{\frac{1}{2}}}$$

η es la tasa de aprendizaje.

Gráficamente

Simulación de una neurona lineal con 2 entradas y actualizando w con la regla de Oja



La propuesta de Oja

Utilizando el polinomio de Taylor en η

$$w_j^{n+1} = \frac{w_j^n}{\|\mathbf{w}\|} + \eta \left(\frac{y(\mathbf{x}^n) \mathbf{x}_j^n}{\|\mathbf{w}\|} - \frac{w_j \sum_{j=1}^N y(\mathbf{x}^n) \mathbf{x}_j^n w_j}{\|\mathbf{w}\|^3} \right) =$$

$$\frac{w_j^n}{\|\mathbf{w}\|} + \eta \left(\frac{y(\mathbf{x}^n) \mathbf{x}_j}{\|\mathbf{w}\|} - \frac{w_j^n y(\mathbf{x}^n) \sum_{j=1}^N \mathbf{x}_j^n w_j^n}{\|\mathbf{w}\|^3} \right) =$$

La regla de aprendizaje de Oja en el paso n

$$\Delta w_j = \eta(y * x_j^n - y^2 * w_j^n)$$


η es la tasa de aprendizaje.

Con esta regla...

- $|w|$ se mantiene acotado.
- Luego de varias iteraciones el método converge al autovector correspondiente al mayor autovalor de la matriz de correlaciones de los datos de entrada.
- Con este vector w_{final} se construye la primer componente principal.

Gráficamente

Simulación de una neurona lineal con 2 entradas y actualizando w con la regla de Oja



Algoritmo

input: N datos con media 0; η , w_{inic}

- 1 for epoch in 1:epoca
 - 1 for i in 1: N
 - 1 $s = \sum_j (\text{datos}[i, j] * w_j)$
 - 2 $w = w + \eta * s * (\text{datos}[i,] - s * w)$
- 2 return(w)

$\text{datos}[i,]$ significa toda la entrada i

Extensión de la regla de Oja

Regla de Sanger 1989 [5]

- Converge a la matriz de autovectores de la matriz de covarianzas de los datos.
- Permite encontrar todas las componentes principales.

Regla de Sanger

- $\mathbf{y} = W^t \mathbf{x}$ donde $\mathbf{y} = (y_1, \dots, y_k)$, $\mathbf{x} = (\mathbf{x}_1, \dots, \mathbf{x}_m)$ y $W = (\mathbf{w}_1, \dots, \mathbf{w}_k)$
- Permite encontrar los primeros k autovectores y por lo tanto las primeras k componentes principales, utilizando la regla de Sanger.

Regla de Sanger

- $y_i^{n+1} = \sum_{j=1}^N w_{ij}^n x_j^n$
- $w_{il}^{n+1} = w_{il}^n + \eta y_i^n (x_l - \sum_{j=1}^i y_j^n w_{jl}^n)$

$$1 \leq i \leq k, 1 \leq k \leq N, 1 \leq l \leq N, \eta \geq 0$$

En cada paso le resta todas las componentes encontradas en los pasos anteriores.

Referencias

- Metodos Hopfield [1].
- Método de Kohonen [3, 4].
- Para todos los métodos [2].

Referencias

- [1] McKay D.J.C. *Hopfield Networks*. Information Theory, Inference and Learning Algorithms, Cambridge, 2003.
- [2] Anders Krogh John Hertz and Richard Palmer. *Introduction to the Theory of Neural Computation*. Addison-Wesley, 1991.
- [3] T. Kohonen. Self-organized formation of topologically correct feature maps. *Biological Cybernetics*, 1(43):59–69, 1982.
- [4] T. Kohonen. The self-organizing map. *Neurocomputing*, pages 1–6, 1998.
- [5] T. D. Sanger. Optimal unsupervised learning in a singlelayer linear feedforward neural network. *Neural Networks*, 2(6):459–473, 1989.